Bazy danych 2025

6 marca 2025

Typy baz danych: SQL/NoSQL

- relacyjne (np. Oracle, MySQL, SQL Server, PostgreSQL, SQLite), multi-model
- klucz-wartość (np. Redis),
- dokumentowe (np. MongoDB),
- grafowe (np. Neo4j),
- wyszukiwarki (full-text search, np. Elasticsearch, SOLR),
- szerokokolumnowe? (wide-column stores, np. BigTable, Cassandra),
- przestrzenne (spatial, np. PostGIS),
- wektorowe (np. Kdb, Pinecone)
- szeregi czasowe (np. Influx)

*(. . .) we are gearing up for a shift to **polyglot persistence** where any decent sized enterprise will have a variety of different data storage technologies for different kinds of data. There will still be large amounts of it managed in relational stores, but increasingly we'll be first asking how we want to manipulate the data and only then figuring out what technology is the best bet for it.* Martin Fowler

Popularność: https://db-engines.com/en/ranking

424 systems in ranking, February 2025

Rank			DBMS	Database Model	Score		
Feb 2025	Jan 2025	Feb 2024			Feb 2025	Jan 2025	Feb 2024
1.	1.	1.	Oracle	Relational, Multi-model	1254.82	-3.93	+13.38
2.	2.	2.	MySQL	Relational, Multi-model	999.99	+1.84	-106.67
3.	3.	3.	Microsoft SQL Server	Relational, Multi-model	786.87	-11.69	-66.70
4.	4.	4.	PostgreSQL	Relational, Multi-model	659.62	-3.79	+30.21
5.	5.	5.	MongoDB	Document, Multi-model	396.63	-5.87	-23.73
6.	↑ 7.	6.	Redis	Key-value, Multi-model	157.91	+4.55	-2.80
7.	↓ 6.	↑ 9.	Snowflake	Relational	155.58	+1.68	+28.13
8.	8.	↓ 7.	Elasticsearch	Multi-model	134.63	-0.29	-1.11
9.	9.	↓ 8.	IBM Db2	Relational, Multi-model	125.44	+2.46	-6.79
10.	10.	10.	SQLite	Relational	113.82	+7.13	-3.47
11.	11.	↑ 12.	Apache Cassandra	Wide column, Multi-model	102.58	+3.39	-6.69
12.	12.	↓ 11.	Microsoft Access	Relational	96.54	+3.84	-16.63
13.	13.	↑ 17.	Databricks	Multi-model	90.03	+2.19	+13.13
14.	14.	↓ 13.	MariaDB	Relational, Multi-model	89.50	+3.92	-7.73
15.	15.	↓ 14.	Splunk	Search engine	80.56	-2.53	-11.09
16.	↑ 17.	↓ 15.	Amazon DynamoDB	Multi-model	75.58	+2.58	-7.31
17.	↓ 16.	↓ 16.	Microsoft Azure SQL Database	Relational, Multi-model	72.76	-1.02	-6.80
18.	18.	18.	Apache Hive	Relational	62.49	+5.61	-3.32
19.	19.	19.	Google BigQuery	Relational	54.89	+1.85	-8.74

Trendy: https://db-engines.com/en/ranking_trend

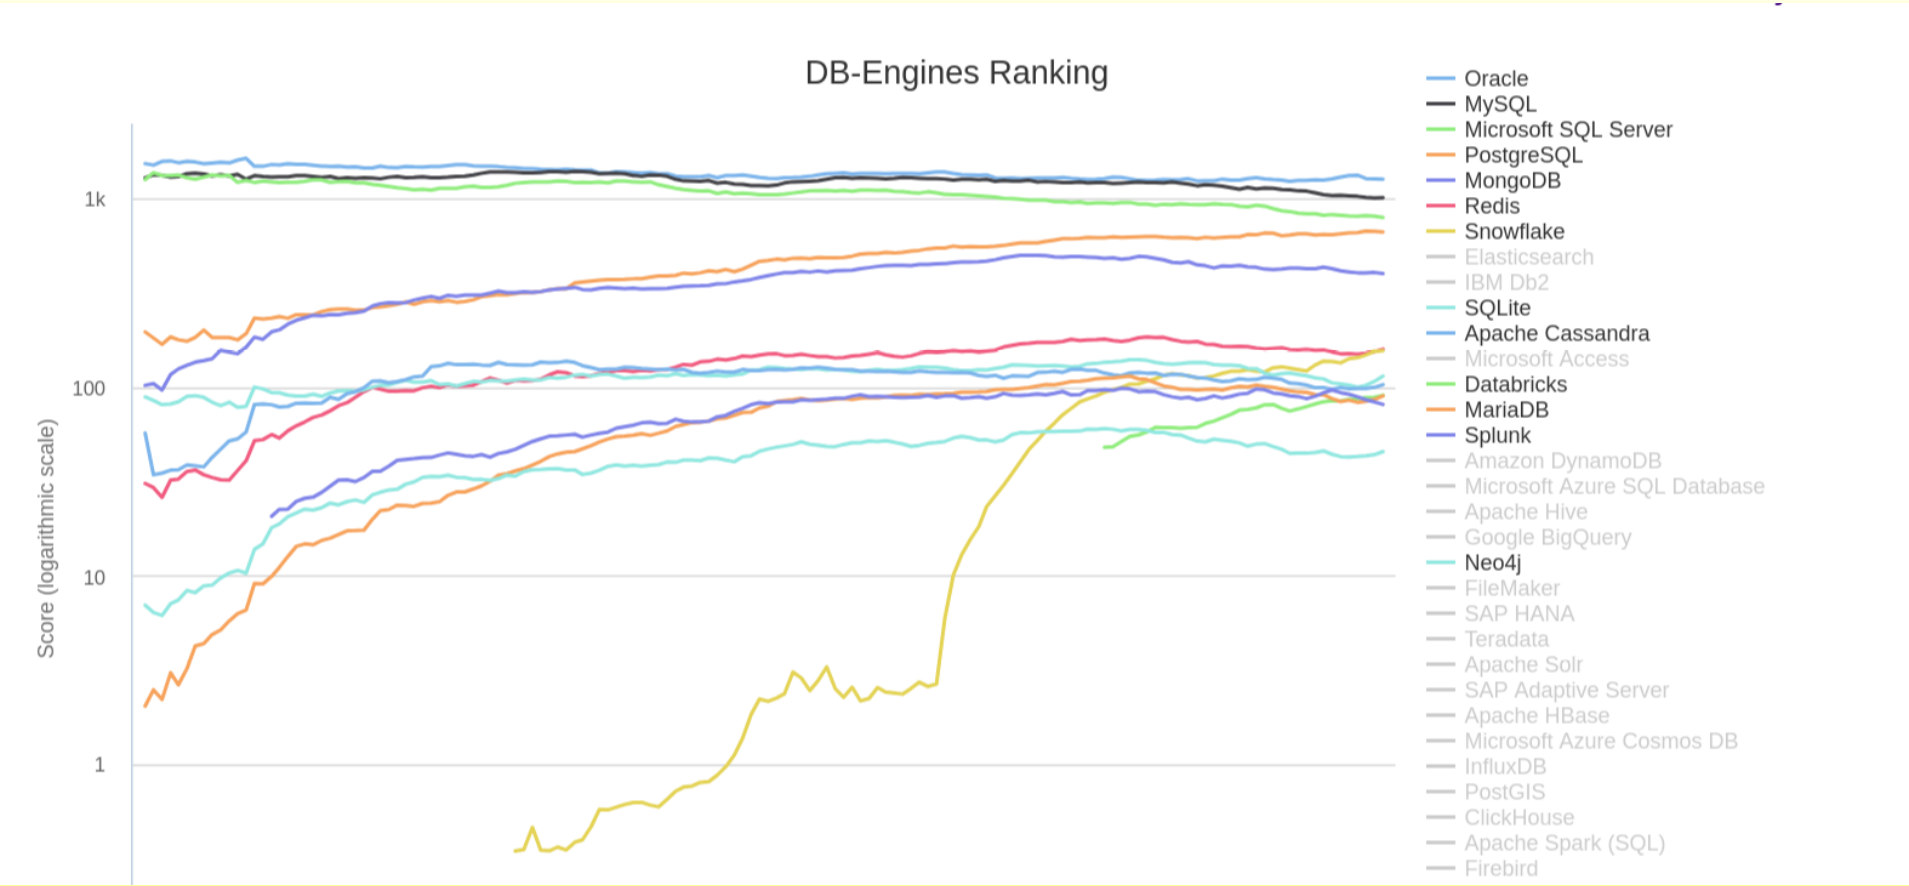

Relacyjne bazy danych

Relacyjne bazy danych

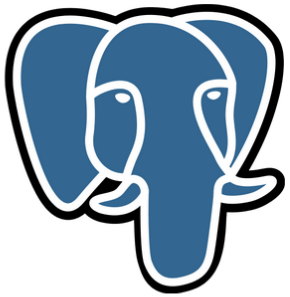

Relacyjne bazy danych

"n.id"	"n.screen_name"	"n.followers_count"	"n.friends_count"	"n.location"
2531159968	"traceyhappymom"	3696	3353	"Washington, DC"
100345056	"SCOTTGOHARD"	1053	1055	"still ⬆Block↰Corner⬇street"
247165706	"Beckster319"	650	896	"Chicago, IL"
249538861	"skatewake1994"	44	154	""
449689677	"KadirovRussia"	94773	7	""
471868887	"MargoSavazh"	23305	8021	"Санкт-Петербург, Россия"
1039581360	"darknally"	22	40	"Amerika"
1510488662	"lagonehoe"	3080	2369	"USA"
1513801268	"YouJustCtrlC"	2760	2700	"USA"
1517678892	"MrMoraan"	879	758	"Philadelphia, PA"
1518857420	"NoJonathonNo"	789	440	"USA"

Relacyjne bazy danych

"n.id"	"n.screen_name"	"n.followers_count"	"n.friends_count"	"n.location"
2531159968	"traceyhappymom"	3696	3353	"Washington, DC"
100345056	"SCOTTGOHARD"	1053	1055	"still ⬆Block⬅Corner⬇street"
247165706	"Beckster319"	650	896	"Chicago, IL"
249538861	"skatewak			
449689677	"KadirovF			
471868887	"MargoSav			
1039581360	"darknall			
1510488662	"lagonehc			
1513801268	"YouJustC			
1517678892	"MrMoraar			
1518857420	"NoJonath			

"n.tweet_id"	"n.user_key"	"n.created_str"	"text"
836227891897651201	"kathiemrr"	"2017-02-27 14:54:00"	"ThingsDoneByMist
765198948239810561	"traceyhappymom"	"2016-08-15 14:50:20"	"T @mc_derpin: #T
616002306572746752	"evewebster373"	"2015-06-30 21:56:09"	"T @dmataconis: R
776693302926147584	"blacktolive"	"2016-09-16 08:04:48"	"men! #blacklives
777594647875059712	"jacquelinisbest"	"2016-09-18 19:46:25"	"T @NahBabyNah: T
718040061649031168	"judelambertusa"	"2016-04-07 11:37:45"	"T @mcicero10: #B
785586729579196416	"carriethornthon"	"2016-10-10 21:04:06"	"T @ItsJustJaynie
664592113775022084	"johnbranchh"	"2015-11-11 23:54:42"	"TodayCleveland '
782408661389840384	"march_for_trump"	"2016-10-02 02:35:35"	"NickTomaWBRE Hi,
811580868573691904	"puredavie"	"2016-12-21 14:35:32"	"hat. Is. A. Reso
800655998335774720	"daileyjadon"	"2016-11-21 11:04:00"	"ifetime movie
822266545728585728	"evagreen69"	"2017-01-20 02:16:36"	"T @Conservatexia
795661161282891776	"cassieweltch"	"2016-11-07 16:16:18"	"T @HillaryClinto
777859822679158784	"_nickluna_"	"2016-09-19 13:20:08"	"T @leonpui_: Hil

Relacyjne bazy danych

"n.id"	"n.screen_name"	"n.followers_count"	"n.friends_count"	"n.location"
2531159968	"traceyhappymom"	3696	3353	"Washington, DC"
100345056	"SCOTTGOHARD"	1053	1055	"still ⬆Block⬅Corner⬇street"
247165706	"Beckster319"	650	896	"Chicago, IL"
249538861	"skatewak			
449689677	"KadirovF			

"n.tweet_id"	"n.user_key"	"n.created_str"	"text"
836227891897651201	"kathiemrr"	"2017-02-27 14:54:00"	"ThingsDoneByMist
765198948239810561	"traceyhappymom"	"2016-08-15 14:50:20"	"T @mc_derpin: #T
72746752	"evewebster373"	"2015-06-30 21:56:09"	"T @dmataconis: R
26147584	"blacktolive"	"2016-09-16 08:04:48"	"men! #blacklives
75059712	"jacquelinisbest"	"2016-09-18 19:46:25"	"T @NahBabyNah: T
49031168	"judelambertusa"	"2016-04-07 11:37:45"	"T @mcicero10: #B
79196416	"carriethornthon"	"2016-10-10 21:04:06"	"T @ItsJustJaynie
75022084	"johnbranchh"	"2015-11-11 23:54:42"	"TodayCleveland '
89840384	"march_for_trump"	"2016-10-02 02:35:35"	"NickTomaWBRE Hi,
73691904	"puredavie"	"2016-12-21 14:35:32"	"hat. Is. A. Reso
35774720	"daileyjadon"	"2016-11-21 11:04:00"	"ifetime movie
28585728	"evagreen69"	"2017-01-20 02:16:36"	"T @Conservatexia
82891776	"cassieweltch"	"2016-11-07 16:16:18"	"T @HillaryClinto
79158784	"_nickluna_"	"2016-09-19 13:20:08"	"T @leonpui_: Hil

	"n.name"	"count"
47		
10	"Trump "	8029
15	"CNN "	1263
15	"GOP "	914
15	"FBI "	762
15	"TRUMP "	675
	"Clinton "	672
	"ISIS "	541
	"MAGA "	479
	"YouTube "	411
	"Twitter "	403
	"wikileaks "	377
	"Obama "	352
	"HRC "	340
	"America "	335
	"Wikileaks "	321

Relacyjne bazy danych

"n.id"	"n.screen_name"	"n.followers_count"	"n.friends_count"	"n.location"
253115998	"traceyhappymom"	3696	3353	"Washington, DC"
100345056	"SCOTTGOHARD"	1053	1055	"still ¦Block¦Corner¦street"
247165706	"Beckster319"	[illegible]	896	"Chicago, IL"
249538861	"skatewak	[illegible]	[illegible]	[illegible]
449689677	"KadirovF	[illegible]	[illegible]	[illegible]

"n.tweet_id"	"n.user_key"	"n.created_str"	"text"
836227891897631201	"kathieorr"	"2017-02-27 14:54:00"	"ThingsDoneByMist
765109948239810561	"traceyhappymom"	"2016-08-15 14:50:20"	"T @mc_derpin: #T
72746752	"evewebster373"	"2015-06-30 21:56:09"	"T @dmataconis: R
26147584	"blacktolive"	"2016-09-16 08:04:48"	"men! #blacklives
75059712	"jacquelinisbest"	"2016-09-18 19:46:25"	"T @NahBabyNah: T
49031168	"judelambertusa"	"2016-04-07 11:37:45"	"T @mcicero10: #B
79196416	"carriethornthon"	"2016-10-10 21:04:06"	"T @ItsJustJaynie
75022084	"johnbranchh"	"2015-11-11 23:54:42"	"TodayCleveland '
89840384	"march_for_trump"	"2016-10-02 02:35:35"	"NickTomaWBRE Hi,
73691904	"puredavie"	"2016-12-21 14:35:32"	"hat. Is. A. Reso
35774720	"daileyjadon"	"2016-11-21 11:04:00"	"ifetime movie
28585728	"evagreen69"	"2017-01-20 02:16:36"	"T @Conservatexia
82891776	"cassieweltch"	"2016-11-07 16:16:18"	"T @HillaryClinto
79158784	"_nickluna_"	"2016-09-19 13:20:08"	"T @leonpui_: Hil

	"n.name"	"count"
47		
10	"Trump "	8029
15	"CNN "	1263
15	"GOP "	914
15	"FBI "	762
15	"TRUMP "	675
	"Clinton "	672
	"ISIS "	541
	"MAGA "	479
	"YouTube "	411
	"Twitter "	403
	"wikileaks "	377
	"Obama "	352
	"HRC "	340
	"America "	335
	"Wikileaks "	321

Relacyjne bazy danych

"n.id"	"n.screen_name"	"n.followers_count"	"n.friends_count"	"n.location"
253115998	"traceyhappymom"	3696	3353	"Washington, DC"
100345056	"SCOTTGOHARD"	1053	1055	"still ‹Block› Corner‹street"
247165706	"Beckster319"	[illegible]	896	"Chicago, IL"
249538861	"skatewak	[illegible]	[illegible]	[illegible]
449689677	"KadirovF	[illegible]	[illegible]	[illegible]

"n.tweet_id"	"n.user_key"	"n.created_str"	"text"
836227891897631201	"kathieorr"	"2017-02-27 14:54:00"	"ThingsDoneByMist
765198948239810561	"traceyhappymom"	"2016-08-15 14:50:20"	"T @mc_derpin: #T
72746752	"evewebster373"	"2015-06-30 21:56:09"	"T @dmataconis: R
26147584	"blacktolive"	"2016-09-16 08:04:48"	"men! #blacklives
75059712	"jacquelinisbest"	"2016-09-18 19:46:25"	"T @NahBabyNah: T
49031168	"judelambertusa"	"2016-04-07 11:37:45"	"T @mcicero10: #B
79196416	"carriethornthon"	"2016-10-10 21:04:06"	"T @ItsJustJaynie
75022084	"johnbranchh"	"2015-11-11 23:54:42"	"TodayCleveland '
89840384	"march_for_trump"	"2016-10-02 02:35:35"	"NickTomaWBRE Hi,
73691904	"puredavie"	"2016-12-21 14:35:32"	"hat. Is. A. Reso
35774720	"daileyjadon"	"2016-11-21 11:04:00"	"ifetime movie
28585728	"evagreen69"	"2017-01-20 02:16:36"	"T @Conservatexia
82891776	"cassieweltch"	"2016-11-07 16:16:18"	"T @HillaryClinto
79158784	"_nickluna_"	"2016-09-19 13:20:08"	"T @leonpui_: Hil

"n.name"	"count"
"Trump "	8029
"CNN "	1263
"GOP "	914
"FBI "	762
"TRUMP "	675
"Clinton "	672
"ISIS "	541
"MAGA "	479
"YouTube "	411
"Twitter "	403
"wikileaks "	377
"Obama "	352
"HRC "	340
"America "	335
"Wikileaks "	321

W jakich godzinach tweetują osoby z *Washington, DC*?

Relacyjne bazy danych

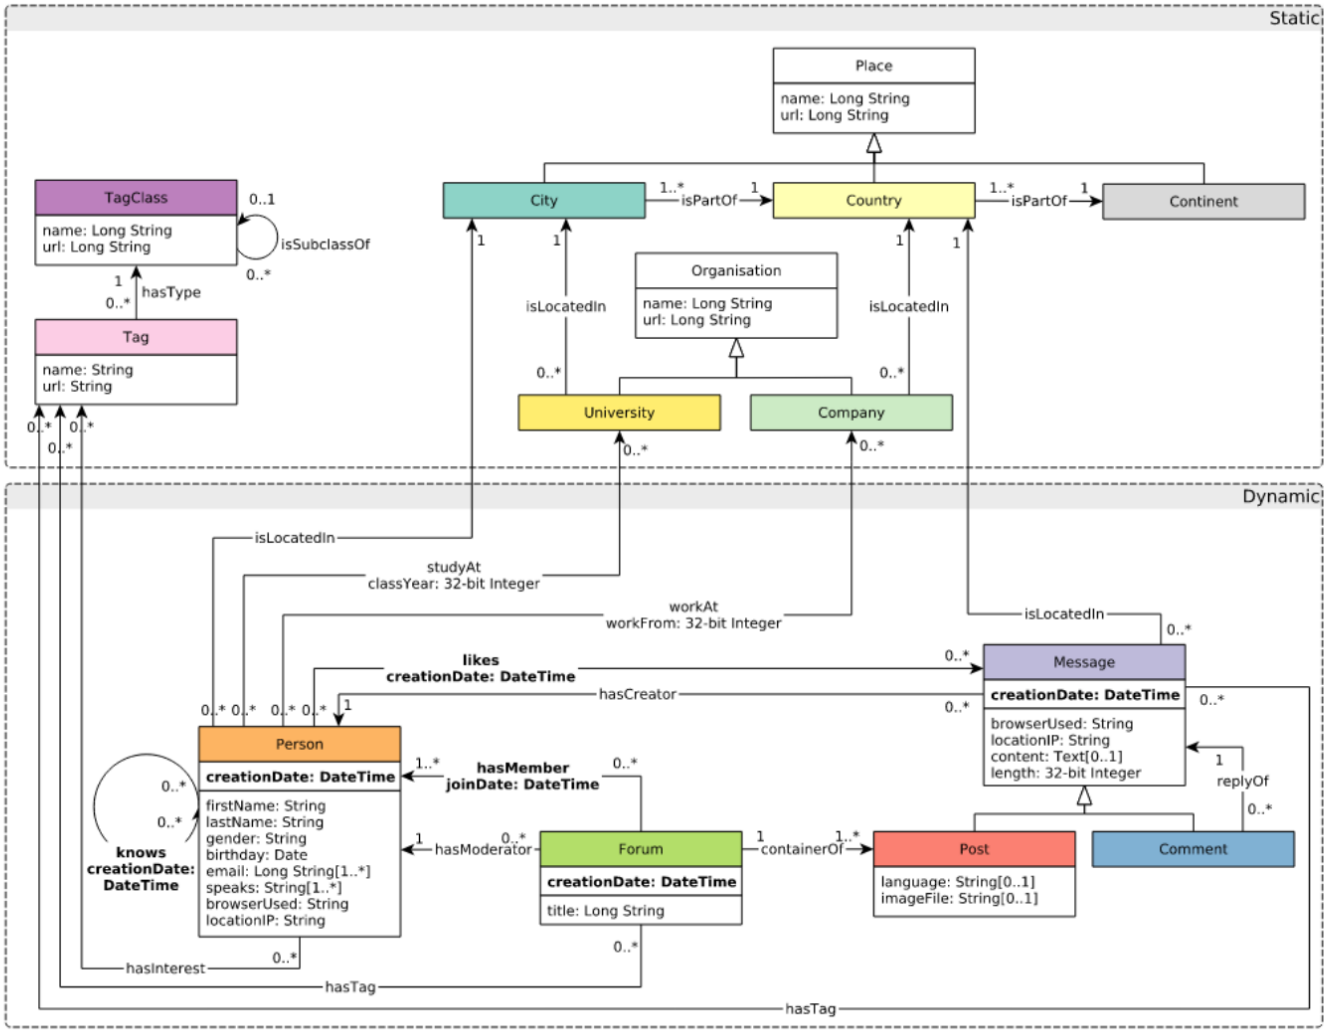

LDBC Benchmark

Relacyjne bazy danych

- prosty model, łatwy w użyciu,
- dane tabelaryczne, nacisk na wartości danych (a nie np. topologię połączeń)
- analiza danych, przegrupowania i agregacje,
- normalizacja - logiczna organizacja danych, brak redundacji i anomalii,

- nie zawsze z góry wiadomo jaka powinna być struktura bazy, jakie dane dokładnie? takie same dla każdego obiektu?
- normalizacja $\rightarrow$ wiele tabel, rozdrobnienie, dużo złączeń,
- podejście zwinne - częste zmiany schematu?
- migracje schematu gdy masz duże dane - kosztowne,
- skalowanie poziome (scale-up vs. scale-out), rozpraszanie, chmury, spójność & dostępność.

NoSQL: key-values stores, document stores

```
{ "id": "PW1",
  "name": "Piotr Wieczorek",
  "company" {
        "name": "II UWr",
        "director": "JMA",
        "location": "...",
        "othercompanydata": "a lot of (pre-joined) data on II UWr"
        },
  "latitude": 51.11092212666858,
  "longitude": 17.05313385578201,
  "expertise": [
      "graph databases",
      "PostgreSQL",
      "MongoDB"
  ]
}
```

https://www.json.org/json-en.html

NoSQL: key-values stores, document stores

- brak schematu / elastyczny schemat,
- brak normalizacji $\rightarrow$ redundancja, anomalie,
- duża wydajność/skalowalność kosztem organizacji danych wg pojedynczego klucza (ale są indeksy),
- brak łatwej możliwości modelowania związków pomiędzy danymi (dodawanie `id` jednego dokumentu jako wartość w drugim...),
- przegrupowanie danych, joiny $\rightarrow$ obliczenia po stronie aplikacji,
- przechowywanie już zjoinowanych danych (join at write-time), szybkość odczytu!
- typowe zastosowania: profile użytkownika (web, gry, ...), koszyk zakupowy, rekomendacje, ogłoszenia, cache.

Bazy grafowe

- organizacja danych wspiera chodzenie po krawędziach,
- o wiele prostszy, naturalny model danych,
- property graphs,
- zapytania ścieżkowe (wyrażenia regularne),
- typowe zastosowania: wyszukiwanie połączeń pomiędzy wierzchołkami, bazy wiedzy, dane o sieciach, rekomendacje, fraudy, paczki, farmacja, śledztwa dziennikarskie (np. Panama Papers), centralność (page-rank) *znajdź bossa mafii*, itp.

```
MATCH (p:Product {productName:"Chocolade"})<-[:PRODUCT]-
         (:Order)-[:PURCHASED]->(c:Customer)
RETURN distinct c.companyName;
```

```
MATCH (:Station { name: 'Denmark Hill' })<-[:CALLS_AT]-(d:Stop)
      ((:Stop)-[:NEXT]->(:Stop)){1,3}
      (a:Stop)-[:CALLS_AT]->(:Station { name: 'Clapham Junction' })
RETURN d.departs AS departureTime, a.arrives AS arrivalTime
```

Wyszukiwarki (full-text search, np. PostgreSQL Full Text Search),

```
SELECT 'a fat cat sat on a mat and ate a fat rat'::tsvector @@ 'cat & rat'::tsquery;
?column?
----------
t
```

```
SELECT title
FROM pgweb
WHERE to_tsvector('english', body) @@ to_tsquery('english', 'friend');
```

```
  SELECT title, ts_rank_cd(textsearch, query) AS rank
  FROM apod, to_tsquery('neutrino|(dark & matter)') query
  WHERE query @@ textsearch
  ORDER BY rank DESC
  LIMIT 10;
                      title                        |   rank
  ---------------------------------------------+----------
   Neutrinos in the Sun                           |      3.1
   The Sudbury Neutrino Detector                  |      2.4
   A MACHO View of Galactic Dark Matter           |  2.01317
   Hot Gas and Dark Matter                        |  1.91171
   The Virgo Cluster: Hot Plasma and Dark Matter  |  1.90953
```

Bazy geograficzne np. PostGIS - m.in. mapy, drogi, trajektorie

- **How far is New York from Seattle? What are the units of the answer?**

Note

New York = `POINT(-74.0064 40.7142)` and Seattle = `POINT(-122.3331 47.6097)`

```
SELECT ST_Distance(
  'POINT(-74.0064 40.7142)'::geography,
  'POINT(-122.3331 47.6097)'::geography
  );
```

```
3875538.57141352
```

- **What is the total length of all streets in New York, calculated on the spheroid?**

```
SELECT Sum(
  ST_Length(Geography(
    ST_Transform(geom,4326)
  )))
FROM nyc_streets;
```

```
10421999.666
```

Algebra relacji

- Operatory: $\pi, \sigma, \rho, \times, \cup, \setminus, \bowtie$,
- operacyjny język (mówimy w jaki sposób obliczyć wynik zapytania),
- domyślnie brak grupowania i agregacji (γ) - kalkulator
- ale i tak dajemy radę:
- `movies -`
  `pi movies.id, movies.name, movies.year, movies.rank`
  `(sigma movies.rank < movies2.rank (movies × rho movies2 (movies)))`
-

movies.id	movies.name	movies.year	movies.rank
92616	'Dr. Strangelove or: How I Learned to Stop Worrying and Love the Bomb'	1964	8.7
267038	'Pulp Fiction'	1994	8.7

Algebra relacji

```
EXPLAIN
  SELECT m1.* FROM movies m1
              JOIN movies m2 ON (m1.rank > m2.rank)
              JOIN movies_genre mg ON (m1.id = mg.movies_id )
              WHERE m1.year>1960;
              QUERY PLAN
-----------------------------------------------------------------------------------------
Merge Join
  Merge Cond: (mg.movies_id = m1.id)
  ->  Sort (Sort Key: mg.movies_id)
        ->  Seq Scan on movies_genre mg
        ->  Sort (Sort Key: m1.id)
              ->  Nested Loop
                    Join Filter: (m1.rank > m2.rank)
                    ->  Seq Scan on movies m2
                          ->  Seq Scan on movies m1
                                Filter: (year > 1960)
```

Rachunki relacyjne

- logika I rzędu (first-order logic) przykłady
- język deklaratywny (co chcę mieć w wyniku, a nie jak to policzyć)
- dobry benchmark, dużo wiadomo np. o zawieraniu zapytań, itp.
- łatwy?
- dwa warianty - relacyjny rachunek dziedzin i krotek

Przykład 1

Baza danych

$S = (\underline{indeks}, nazwisko, rok),\ P = (\underline{nazwa}, typ),\ O = (\underline{indeks}, \underline{przed}, \underline{data}, stop)$

- $x \in S \wedge (\exists y)(y \in O \wedge y.indeks = x.indeks \wedge y.stop = 5 \wedge y.przed =' BD')$
- $\{x \mid x \in S \wedge (\exists y)(y \in O \wedge y.indeks = x.indeks \wedge y.stop = 5 \wedge y.przed =' BD')\}$
- $\{z^{[nazwisko, indeks]} \mid$
  $(\exists x)(x \in S \wedge z.indeks = x.indeks \wedge z.nazwisko = x.nazwisko \wedge$
  $(\exists y)(y \in O \wedge y.indeks = x.indeks \wedge y.stop = 5 \wedge y.przed =' BD'))\}$

Znaczenie zapytań

- x - student, który dostał *5.0* z *BD*.
- Wszyscy studenci, którzy dostali *5.0* z *BD*.
- Nazwiska i indeksy studentów, którzy dostali *5.0* z *BD*.

Przykład 2

Baza danych

$S = (\underline{indeks}, nazwisko, rok),\ P = (\underline{nazwa}, typ),\ O = (\underline{indeks}, \underline{przed}, \underline{data}, stop)$

2a. $\{x \mid x \in S \wedge \neg(\exists y)(y \in O \wedge y.indeks = x.indeks \wedge y.stop = 5)\}$

2b. $\{x \mid x \in S \wedge \neg(\exists y)(y \in O \wedge y.indeks = x.indeks \wedge y.stop \neq 5)\}$

2c. $\{x \mid x \in S \wedge (\exists y)(y \in O \wedge y.indeks = x.indeks \wedge y.przed =' BD' \wedge$
$\neg(\exists y_1)(y_1 \in O \wedge y_1.indeks \neq x.indeks \wedge y_1.przed =' BD' \wedge y_1.stop > y.stop)\}$

Znaczenie zapytań

2a. Studenci, którzy nie dostali żadnej piątki.

2b. Studenci, którzy mają tylko piątki.

2c. Studenci, którzy mają najlepszą ocenę z Baz danych.

Zapytanie relacyjnego rachunku krotek

Formuła rrk — opisuje własności krotek

Formuła atomowa:

- $R(t)$ lub $t \in R$, gdzie R to relacja z bazy danych, a t to zmienna (krotkowa);
- $t.a = c$, gdzie a jest atrybutem t; równość można zastąpić przez: $\neq, <, \leq, >, \geq$, a c jest stałą lub atrybutem innej zmiennej krotkowej;

Formuła:

- formuła atomowa,
- (ϕ), $\neg(\phi)$, $\phi \vee \psi$, $\phi \wedge \psi$, gdzie ϕ i ψ są formułami;
- $(\exists t)(\phi(t))$ lub $(\forall t)(\phi(t))$, gdzie ϕ jest formułą, a t jej zmienną wolną.

Zapytanie rrk — wybiera krotki mające daną własność

$$\{x \mid \phi(x)\} \qquad \{x^{[A_1, A_2, \ldots, A_k]} \mid \phi(x)\},$$

gdzie x jest zmienną krotkową, a ϕ jest formułą relacyjnego rachunku krotek, w której x jest jedyną zmienną wolną;

Przykład 1

Baza danych

$S = (\underline{indeks}, nazwisko, rok),\ P = (\underline{nazwa}, typ),\ O = (\underline{indeks}, \underline{przed}, \underline{data}, stop)$

1. $S(x_1, x_2, x_3) \wedge (\exists y_1, y_2, y_3, y_4)((O(y_1, y_2, y_3, y_4) \wedge y_1 = x_1 \wedge y_2 =' BD' \wedge y_4 = 5)$

1a. $S(x_1, x_2, x_3) \wedge (\exists y_3)(O(x_1,' BD', y_3, 5))$

2. $\{x_1, x_2, x_3 \mid S(x_1, x_2, x_3) \wedge (\exists y_3)(O(x_1,' BD', y_3, 5))\}$

3. $\{x_1, x_2 \mid (\exists x_3)(S(x_1, x_2, x_3) \wedge (\exists y_3)(O(x_1,' BD', y_3, 5)))\}$

3a. $\{ind, naz \mid (\exists rok)(S(ind, naz, rok) \wedge (\exists dat)(O(ind,' BD', dat, 5)))\}$

Znaczenie zapytań

1. x - student, który dostał *5.0* z *BD*.
2. Wszyscy studenci, którzy dostali *5.0* z *BD*.
3. Nazwiska i indeksy studentów, którzy dostali *5.0* z *BD*.

Przykład 2

Baza danych

$S = (\underline{indeks}, nazwisko, rok),\ P = (\underline{nazwa}, typ),\ O = (\underline{indeks}, \underline{przed}, \underline{data}, stop)$

2a. $\{(i, n, r) \mid S(i, n, r) \wedge \neg(\exists p, d)(O(i, p, d, 5))\}$

2b. $\{(i, n, r) \mid S(i, n, r) \wedge \neg(\exists p, d, s)(O(i, p, d, s) \wedge s \neq 5)\}$

2c. $\{(i, n, r) \mid S(i, n, r) \wedge (\exists d, s)(O(i,' BD', d, s) \wedge \neg(\exists i_1, d_1, s_1)(O(i_1,' BD', d_1, s_1) \wedge i \neq i_1 \wedge s_1 > s))\}$

Znaczenie zapytań

2a. Studenci, którzy nie dostali żadnej piątki.

2b. Studenci, którzy mają tylko piątki.

2c. Studenci, którzy mają najlepszą ocenę z Baz danych.

Zapytanie relacyjnego rachunku dziedzin

Formuła rrd — opisuje własności wektorów zmiennych dziedzinowych

Formuła atomowa:

- $R(x_1, x_2, \ldots, x_k)$ lub $(x_1, x_2, \ldots, x_k) \in R$, gdzie R to relacja o arności k, $x_1, x_2, \ldots, x_k$ to zmienne lub stałe (dziedzinowe);
- $x = c$, gdzie x jest zmienną; równość można zastąpić przez: $\neq, <, \leq, >, \geq$, a c jest stałą lub zmienną;

Formuła:

- formuła atomowa,
- (ϕ), $\neg(\phi)$, $\phi \vee \psi$, $\phi \wedge \psi$, gdzie ϕ i ψ są formułami;
- $(\exists t_1, t_2, \ldots, t_\ell)(\phi(t_1, t_2, \ldots, t_\ell)$ lub $(\forall t_1, t_2, \ldots, t_\ell)(\phi(t_1, t_2, \ldots, t_\ell)$, gdzie ϕ jest formułą, a $t_1, t_2, \ldots, t_\ell$ jej zmiennymi wolnymi.

Zapytanie rrd — wybiera wektory wartości zmiennych mające daną własność

$$\{x_1, x_2, \ldots, x_\ell \mid \phi(y_1, y_2, \ldots, y_k)\},$$

gdzie ϕ jest formułą relacyjnego rachunku krotek, a $x_1, x_2, \ldots, x_\ell$ to zmienne dziedzinowe i stałe, wśród których występują wszystkie zmienne wolne ϕ: $y_1, y_2, \ldots, y_k$ i tylko takie zmienne;

Mały problem

- Jaka powinna być odpowiedź na zapytanie: $\{x|\neg movies(x)\}$?
- A na $\{x, y|movies(x, 'SomeTitle', 2022, 5) \vee movies(y, 'OtherTitle', 2023, 5)\}$?
- Co jest nie tak?
- W obu przypadkach wynik zależy od przyjętej dziedziny (zbioru dopuszczalnych wartości w kolumnie!)
- AAAAAAAAAAA! Przecież to może być zbiór nieskończony!
- Nawet gdyby dziedzina była skończona to i tak kto pisząc zapytanie pamięta ją całą?
- Formuły, które mogą zwracać nieskończony wynik nie są bezpieczne!
- Matematycy radzą sobie pamiętając osobno dziedzinę - model czyli matematyczna baza danych to dziedzina, sygnatura (=schemat) i interpretacja ($\approx$ stan bazy)
- I niczego się tu nie boją! Dlaczego?
- Inne przykłady: $\{x|R(y)\}, \{x|R(x) \vee R(y)\}, \{x|R(x) \vee \neg R(x)\}$

Mały problem

Bardziej skomplikowany przykład

$E(osoba, temat)$ to baza ekspertów z określonych tematów. Poszukujemy pary ekspertów, którzy razem tworzą zespół znający się na wszystkich tematach.

$\{a, b \mid (\forall d)((\exists c)(E(c, d)) \Rightarrow E(a, d) \vee E(b, d))\}$

$\{x \mid P(x) \wedge (\forall y)S(y)\}$ Skończony! Mamy rozwiązanie?

$\{x \mid P(x) \wedge (\forall y)L(x, y)\}$?

Co jest nie tak?

- Szukamy takich par (a, b), że dla każdego tematu d (czyli zmiennej występującej w drugiej kolumnie E) a lub b jest ekspertem w tym temacie (występuje w parze z d w relacji E).
- Jeśli nie ma tematów (E jest pusta), to każda para wartości $(?, ?)$ spełnia formułę zapytania.
- Jeśli jest jeden ekspert *Wszystkowiedzący* znający się na wszystkim, to każda para $(\text{'Wszystkowiedzący'}, ?)$ spełnia formułę zapytania.
- Zapytania mogą zależeć od dziedziny nawet jak są skończone!

Niezależność od dziedziny (domain independence)

Niech $\phi_B(\mathcal{A})$ oznacza zbiór krotek będący wynikiem zapytania ϕ obliczonego na bazie $\mathcal{A}$ przy założeniu, że dziedzina (zbiór możliwych wartości zmiennych) to B.

Dziedzina aktywna formuły

Zbiór D nazwiemy **dziedziną aktywną** formuły ϕ i bazy $\mathcal{A}$, gdy jest to zbiór wszystkich wartości występujących we wszystkich kolumnach wszystkich relacji z $\mathcal{A}$ oraz wszystkich stałych występujących jawnie w ϕ.

Zapytanie ϕ jest *dziedzinowo niezależne* wtedy i tylko wtedy gdy nie istnieje:

- taka baza danych $\mathcal{A}$ oraz
- dwie dziedziny D_1 i D_2 zawierające dziedzinę aktywną ϕ i $\mathcal{A}$ takie, że $\phi_{D_1}(\mathcal{A}) \neq \phi_{D_2}(\mathcal{A})$.

Zapytania dziedzinowo niezależne będziemy wyliczać na dziedzinie aktywnej i będziemy nazywać je bezpiecznymi
Czy może zdarzyć się, że dostaniemy inny wynik niż w semantyce standardowej?

Niezależność od dziedziny (domain independence)

W informatyce nie lubimy jak formuła zależy od dziedziny.

Sprawdzenie czy formuła jest dziedzinowo niezależna jest nierozstrzygalne!

Istnieją (jakieś) syntaktyczne ograniczenia zapewniające bezpieczeństwo.

Uwaga! Na formułę, która zwraca nieskończony wynik mówi się, że jest niebezpieczna
Czy istnieje formuła, które nie jest bezpieczna ani niebezpieczna?
Praca: ON SAFETY, DOMAIN INDEPENDENCE, AND CAPTURABILITY OF DATABASE QUERIES

Czy zapytania algebry relacji są dziedzinowo niezależne?

Ciekawostka: rel

RelationalAI Docs

RKGS
WHY RKGS?
RAI CONSOLE
SDK GUIDES
CONCEPTS
VS CODE EXTENSION
REL
REL PRIMER
HOW-TO GUIDES
CONCEPTS
REFERENCE
CHEATSHEET
HELP
ERROR MESSAGES

Existential and Universal Quantification

- `exists` is used to express existential quantification.
- `forall` is used to express universal quantification.

Example: *Is there anyone who likes hiking?*

```
// read query

exists(x : liked_activity(x, "hiking"))
// Output: {()} (true)
```

Example: *Does everyone like hiking?*

```
// read query

forall(person in Person : liked_activity(person, "hiking"))
// Output: {} (false)
```

Twierdzenie

Języki zapytań dla modelu relacyjnego:

- *algebra relacji,*
- *relacyjny rachunek krotek i relacyjny rachunek dziedzin*

nie są sobie równoważne.

Każde wyrażenie algebry relacji zwraca zbiór skończony!

Twierdzenie (Twierdzenie)

Języki zapytań dla modelu relacyjnego:

- *algebra relacji,*
- *relacyjny rachunek krotek ograniczony do formuł bezpiecznych i*
- *relacyjny rachunek dziedzin ograniczony do formuł bezpiecznych*

są sobie równoważne.

Proste ćwiczenie 1: Dla każdego wyrażenia algebry relacji istnieje równoważna mu bezpieczna formuła w relacyjnym rachunku krotek. przykłady

Proste ćwiczenie 2: Dla każdej bezpiecznej formuły w relacyjnym rachunku krotek istnieje równoważna mu bezpieczna formuła w relacyjnym rachunku dziedzin.

Twierdzenie 1: Dla każdej bezpiecznej formuły w relacyjnym rachunku dziedzin istnieje równoważne mu wyrażenie algebry relacji.

Pokażemy, że dla każdego $\phi(x_1, \ldots, x_k)$ — bezpiecznej formuły relacyjnego rachunku dziedzin o zmiennych wolnych $x_1, x_2, \ldots, x_k$ istnieje wyrażenie algebry relacji W_ϕ, którego wartością jest $\{x_1, x_2, \ldots, x_k \mid \phi(x_1, x_2, \ldots, x_k)\}$.

1. Zdefiniujmy dziedzinę ϕ:

$$D_\phi \;=\; \{c_1, c_2, \ldots, c_\ell\} \cup \bigcup \pi_{A \in attr(R_i)}(R_i),$$

   gdzie $c_1, c_2, \ldots, c_\ell$ to wszystkie stałe występujące w ϕ, a $R_1, R_2, \ldots, R_m$ to symbole wszystkich relacji występujących w ϕ.

2. Przekształćmy formuły atomowe występujące w ϕ tak, by nie zawierały stałych i powtarzających się zmiennych:

$$R(x, y, x, 13) \;\rightarrow\; (\exists z, u) R(x, y, z, u) \wedge x = z \wedge u = 13$$

3. Przekształćmy ϕ w ten sposób, by nie zawierała spójników $\wedge$ i kwantyfikatorów $\forall$.

Podstawa indukcji

- dla $\phi(x, y, z) \equiv R(x, y, z)$ definiujemy

$$W_\phi = R, \quad \textit{ewentualnie} \quad W_\phi = \rho_{x,y,z}(R)$$

- dla $\phi(x) \equiv x > const$ definiujemy

$$W_\phi = \sigma_{x > const}(\rho_x(D))$$

- dla $\phi(x) \equiv x = const$ definiujemy

$$W_\phi = \sigma_{x = const}(\rho_x(D)) \quad \textit{lub} \quad \rho_x(\{const\})$$

- dla $\phi(x, y) \equiv x \neq y$ definiujemy

$$W_\phi = \sigma_{x \neq y}(\rho_x(D) \times \rho_y(D))$$

Krok indukcyjny

- dla $\phi(x) \equiv \neg\psi(x)$ i wyrażenia W_ψ z atrybutem x definiujemy

$$W_\phi = \rho_x(D) \setminus W_\psi$$

- dla $\phi(x, y, z) \equiv \psi(x, y) \vee \eta(y, z)$ i wyrażeń W_ψ i W_η z atrybutami odpowiednio: x, y oraz y, z definiujemy

$$W_\phi = (W_\psi \times \rho_z(D)) \cup (\rho_x(D) \times W_\eta)$$

- dla $\phi(x) \equiv (\exists y)\psi(x, y)$ i wyrażenia W_ψ z atrybutami x, y definiujemy

$$W_\phi = \pi_x(W_\psi)$$

Wnioski

1. Mamy trzy równoważne języki zapytań dla modelu relacyjnego:
   - Dwa z nich, rachunki relacyjne, są deklaratywne — formułując zapytanie podajemy jego znaczenie, a nie sposób obliczania.
   - Jeden z nich, algebra relacji, jest imperatywny — pisząc wyrażenie podajemy sposób wyliczania, ale znaczenie wyrażenia nie musi być jasne.
2. Moc, czyli możliwości ekspresji rachunków relacyjnych, jest bardzo dobrze znana:
   - to logika pierwszego rzędu, w której można opisać wiele własności,
   - nie można jednak wyrazić np. domknięcia tranzytywnego, do czego potrzebne jest kwantyfikowanie po relacjach (powiedzenie, że "istnieje relacja, taka że...),
   - łatwiej zastanawiać się czy zapytania są równoważne lub zawierają się w sobie (optymalizacje!).

Zapytania koniunkcyjne

- Wiele naturalnych własności można wyrazić wyrażeniami algebry relacji używającymi wyłącznie selekcji, projekcji, złączeń i przemianowań.
- Fragmentowi temu odpowiadają zapytania koniunkcyjne, są to formuły rrd/rrk postaci

$$\varphi(\vec{x}) = \exists \vec{y} \bigwedge_i R_i(\vec{x}, \vec{y})$$

- Co właściwie da się zapisać w tak prostym języku? przykłady

Baza danych

Na każdą bazę danych możemy patrzeć jak na

- zbiór tabel,
- strukturę relacyjną,
- zbiór faktów.