Lista zadań nr 5 (normalizacja)
Bazy Danych 2025

Pomóż zaprojektować bazę danych dla Wydziału Przestępczości Zorganizowanej (WPZ). Tajne służby opracowały już listę najbardziej zagrożonych miast oraz najbardziej złowieszczych procederów. Ustalono też ponad wszelką wątpliwość, że jeśli gang uprawia jakiś proceder to uprawia go we wszystkich miastach, w których jest obecny, a jeśli jest obecny w jakimś mieście to uprawia w nim wszystkie procedery, które uprawia gdziekolwiek.

W tej chwili baza składa się z relacji: `Mafia(Miasto, Gang, Proceder, Szef, Dochód, ROI)`. Wiadomo też, że zachodzą zależności funkcyjne to: `Gang` $\rightarrow$ `Szef`, `Szef` $\rightarrow$ `Dochód`, `Proceder` $\rightarrow$ `ROI`.

1. **(0.5 pkt)** Podaj definicję postaci BCNF. Czy powyższa baza jest w tej postaci? Dlaczego? Zaproponuj taki rozkład bazy do postaci BCNF, który jest odwracalny i zachowuje wszystkie zależności. Nie rozkładaj jakiejkolwiek tabeli, która już jest w postaci BCNF.

2. **(0.5 pkt.)** Czy mimo tego, że baza (po Twoich modyfikacjach) jest w postaci BCNF dostrzegasz w niej jeszcze jakąś oczywistą redundancję? Jaka jest jej przyczyna?

3. **(0.5 pkt.)** Czy istnieje odwracalny rozkład pozwalający się tej redundancji pozbyć? Podaj go. Dlaczego jest on odwracalny?

4. **(0.5 pkt)** Napisz zapytanie algebry relacji zwracające niepustą odpowiedź wtedy i tylko wtedy gdy w relacji `Mafia` naruszona jest zależność funkcyjna `Proceder` $\rightarrow$ `ROI`.

5. **(1 pkt)** Rozważamy relację $S(F, M, R)$. Zależność wielowartościowa $F \twoheadrightarrow M$ zachodzi wtw, gdy dla każdych dwóch krotek $t_1, t_2 \in S$ takich, że $\pi_F(t_1) = \pi_F(t_2)$ istnieje krotka $t \in S$ taka, że:

   1. $\pi_{FM}(t) = \pi_{FM}(t_1)$,
   2. $\pi_{FR}(t) = \pi_{FR}(t_2)$.

   Udowodnij lub pokaż kontrprzykład:

   1. Jeśli $F \twoheadrightarrow M$ to $F \rightarrow M$.
   2. Jeśli $F \rightarrow M$ to $F \twoheadrightarrow M$.

   Jeśli w bazie danych wszystkie zależności wielowartościowe zależą od (nad)klucza to mówimy, że baza jest w 4. postaci normalnej (4NF).

6. **(1 pkt)** Jednym z najważniejszych obecnie modeli danych dla grafów są tzw. *property graphs* (przykład na rys. 1). Grafy w tym modelu składają się z wierzchołków i krawędzi. Wierzchołki i krawędzie mogą posiadać wiele *własności*, które są parami klucz-wartość. Zaproponuj sensowny sposób przechowywania takich grafów w relacyjnej bazie danych.

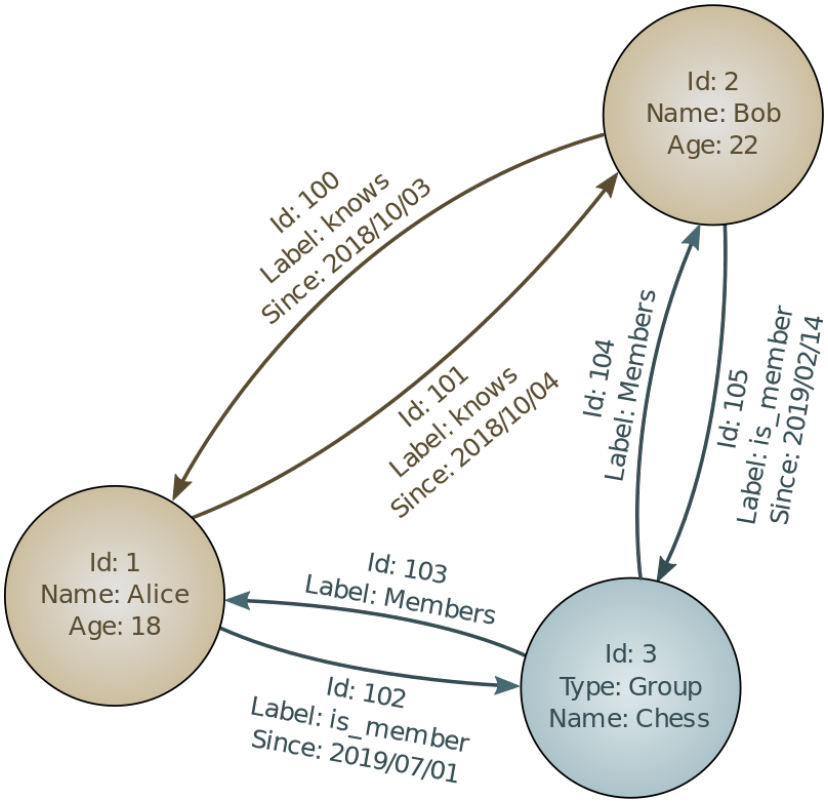

Rysunek 1: Property graph

7. (1 pkt) Tradycyjnie bardzo rzadko stosowało się postacie normalne powyżej BCNF (np. 4NF). Cała teoria normalizacji powyżej BCNF była uważana za odległą od praktyki.

W dużej mierze wynikało to z faktu, że sposoby wyliczania złączeń w bazach danych zakładały, że operator złączenia jest binarny (łączymy dwie tabele, wynik złączenia z kolejną itd.). W nowoczesnych rozwiązaniach czasami opłaca się posunąć normalizację aż do skrajności - każda tabela posiada co najwyżej jedną kolumnę, która nie jest częścią klucza (tzw. 6. postać normalna, 6NF). Jedną z zalet takiego podejścia jest chęć wykonywania złączeń wielu tabel jednocześnie (*worst-case optimal multi-way joins*).

Zmodyfikuj rozwiązanie poprzedniego zagadnieniach tak aby property graphs przechowywać w 6NF.

8. (1 pkt) Rozważmy relację R, w której zachodzi zależność funcyjna $\xi = \alpha \to \beta$, gdzie $\alpha \cap \beta = \emptyset$ oraz α i β są podzbiorami atrybutów R. Udowodnij, że rozkład relacji R wg ξ, na relacje R_1 z atrybutami $\alpha \cup \beta$ oraz R_2 z atrybutami $\text{attr}(R) \setminus \beta$ jest odwracalny.