Bazy danych 2025

29 marca 2025

Wartość pusta (NULL)

PESEL : `char(11)`	Adres : `varchar(50)`	Metraż : `real`	
...			
NULL	Poznań, Szeroka 10/12	64,2	$\Leftarrow t_1$
NULL	Ełk, Kwiatowa 102	64,2	$\Leftarrow t_2$
...			

- t_1.PESEL $=$ t_2.PESEL UNKNOWN!!!
- t_1.PESEL $=$ t_1.Adres UNKNOWN!!!
- t_1.Metraż $=$ t_2.Metraż TRUE
- t_1.Adres $=$ t_2.Adres FALSE
- t_1.PESEL $=$ *NULL* UNKNOWN!!!
- t_1.PESEL $=$ `''` UNKNOWN!!!
- t_1.PESEL IS NULL TRUE
- t_1.Adres IS NOT NULL TRUE

Wartość NULL

Może oznaczać, że

1. nie znamy danej wartości (np. student już dostał ocenę ale nie wiadomo jaką, awaria czujnika, itp.)
2. dana wartość w ogóle nie jest jeszcze zdefiniowana (np. egzamin się jeszcze nie odbył, data kasacji, itp.)
3. dana wartość jest nieobecna *by design* - prawdopodobnie zły projekt bazy (np. numer indeksu dla nie-studenta, poprzednik pierwszego elementu);

- W scenariuszu pierwszym - NULLe reprezentujemy jako zmienną z danej dziedziny.

id	nazwisko	ocena
1	Kowalski	5
2	Nowak	x
3	y	4.5
v	w	z

- zły projekt bazy (np. 10 kolumn na numery telefonów) vs. *bazy semistrukturalne* $\rightarrow$ json
- w 6NF nigdy nie potrzeba nulli! (przykład na tablicy)
- różne rzeczy się komplikują - logika trójwartościowa!
- czy dla UNKNOWN warunek selekcji jest spełniony czy nie? a jego zaprzeczenie(!!!)?
- a więz (np. wynik_matury $<=$ 100) jest spełniony ? a jego zaprzeczenie(!!!)?
- możesz coś komuś sprzedać bez zapłaty, nie przechwycisz wrogiej rakiety - szczegóły w części o SQL
- wartości NULL i złączenia $\rightarrow$ złączenia zewnętrzne
- COUNT(*) vs COUNT(actors.id) vs. COUNT(actors.gender)

Dobry projekt bazy danych

NULL-e — krotki powinny pasować do schematu tabeli,

Redundancja — informacja nie powinna być zapisywana wielokrotnie,

Kontrola więzów — sprawdzanie własności klucza, unikalności i innych więzów powinno być łatwe,

Obliczanie złączeń — jest trudne, więc nie należy rozdrabniać zbytnio bazy.

Dobry projekt bazy danych - anomalie

GR(idg, nazwa_przedmiotu, opis_przedmiotu, prow_nazwisko, prow_biuro, lista_zapisanych_w_json)

złożone typy — lista_zapisanych_w_json → Zapisy(ids, idg, data_zapisu) **1NF**

Codd: *to permit data to be queried and manipulated using a "universal data sub-language"*

anomalia UPDATE — zmiana biura prowadzącego → zmiana w wielu miejscach (redundacja, niejednoznaczność)

anomalia INSERT — jak dodać nowego prowadzącego (bez grup)? Null? jaki klucz główny?

anomalia DELETE — co po usunięciu ostatniej grupy prowadzącego?

zalety ? nie ma joinów!!! kiedy to jest dobrze, a kiedy źle?

Dobry projekt bazy danych - rozwiązanie

GR(idg, nazwa_przedmiotu, opis_przedmiotu, prow_nazwisko, prow_biuro, lista_zapisanych_w_json)
Propozycje?

- Grupa(idg, id_przed, id_prow, inne_dane_grupy)
- Prowadzący(id_prow, prow_nazwisko, prow_biuro)
- Zapisy(id_stud, idg, data_zapisu)
- Przedmioty(id_przed, opis_przedmiotu)

Trzeba uważać aby dobrze ustalić co jest atrybutem czego!
Przedmioty(id_przed, opis_przedmiotu, konsultacje_biuro) ???
Grupa(idg, id_przed, id_prow, inne_dane_grupy, konsultacje_biuro) ???

Co jak dwóch prowadzących prowadzi jedną grupę? Albo co gdy zmienimy pokój prowadzącemu?

Normalizacja

- Rozbijamy dane tak aby nie było redundancji
- Pilnując różnych zależności
- Najlepiej rozrysować to sobie z użyciem diagramów ER (będzie wiecej o tym!)
- Czasem lepiej odpuścić aby nie robić tylu joinów (świadoma decyzja!)

Skąd się biorą redundancje?

GR(idg, nazwa_przedmiotu, opis_przedmiotu, prow_nazwisko, prow_biuro,

- Kluczem jest **idg**
- Każda grupa z danego przedmiotu ma powtórzone dane przedmiotu
- Każdy prowadzący ma powtórzone dane w każdym swoim przedmiocie
- Podzbiór kolumn jest **determinowany** przez coś co nie jest kluczem!
- nazwa_przedmiotu $\rightarrow$ opis_przedmiotu
- prow_nazwisko $\rightarrow$ prow_biuro

Definicja i przykład

Definition (Zależność funkcyjna)

Dla relacji $R = A_1 A_2 \ldots A_k$ oraz zbiorów jej atrybutów $\alpha, \beta \subseteq \{A_1 A_2 \ldots A_k\}$ zachodzi zależność funkcyjna $\alpha \rightarrow \beta$, jeżeli dla każdego stanu r relacji R zachodzi:

$$(\forall t_1, t_2 \in r)((t_1.\alpha = t_2.\alpha) \;\Rightarrow\; (t_1.\beta = t_2.\beta))$$

Kolumny α determinują kolumny β! Tyle!

W relacjach PR(ido,tytuł,nazwisko,adres), ST(ido,indeks,nazwisko,adres) i GR(idg,idk,idp,limit), TS(idg,termin,sala) zachodzą zależności

- w PR: ido $\rightarrow$ nazwisko,adres,tytuł,
- w ST: ido $\rightarrow$ nazwisko,adres,indeks oraz indeks$\rightarrow$ ido,nazwisko,adres;
- w GR: idg$\rightarrow$ idk,idp,limit
- w TS: termin,sala$\rightarrow$ idg

Zależności funkcyjne

Spostrzeżenie: Jeśli K jest kluczem R, to $K \to R$.

Spostrzeżenie: Zależność funkcyjna to własność rzeczywistości, nie danych!
Spostrzeżenie: Na podstawie danych można tylko sprawdzić czy istnieje kontrprzykład dla danej zależność. Nie da się ustalić czy zależność zachodzi!

Przykład

- `Mafia(Miasto, Gang, Proceder)`
- ξ_1: `Gang` $\rightarrow$ `Miasto` oraz ξ_2: `Miasto, Proceder` $\rightarrow$ `Gang`.
- Co można wywnioskować o organizacji mafii wiedząc, że zachodzą ξ_1 i ξ_2?
- Czy jeden gang może trudnić się wieloma procederami?
- Jakie są klucze relacji `Mafia`?
- Anomalie?
- Podaj odwracalny rozkład relacji `Mafia` do postaci BCNF(!?).
- BCNF?
- Rozkład?
- Odwracalny?
- Czy rozkład ten zachowuje zależności?
- Jakie rodzi to problemy?
- Czyli jak SZBD pilnuje zależności w bazie?

Postać normalna Boyce-Codda

Definition (Postać normalna Boyce-Codda, BCNF)

Relacja R ze zbiorem zależności funkcyjnych F jest w postaci normalnej Boyce-Codda, jeśli dla każdej nietrywialnej zależności $\alpha \rightarrow \beta$ ($\alpha \cap \beta = \emptyset$) zbiór α jest nadkluczem.

Uwagi:

1. Relacja w BCNF ma tylko zależności trywialne i wynikające z nadklucza.
2. Kontrola zależności funkcyjnych w relacji w BCNF sprowadza się do kontroli własności klucza.

Przykłady:

1. `Mafia(Miasto, Gang, Proceder)`,
2. `Gang` $\rightarrow$ `Miasto`; `Miasto, Proceder` $\rightarrow$ `Gang`
3. `Lokalizacje(Miasto, Gang)`, `Procedery(Gang, Proceder)` są w BCNF
4. `Miasto, Proceder` $\rightarrow$ `Gang`
5. może być niespełniona inne sposoby np. trigger

Rozkład relacji

- Rozkładem relacji R nazywamy zbiór relacji $\{R_1, \ldots, R_k\}$ taki, że $R = R_1 \cup \ldots \cup R_k$.
- Oznaczmy przez F^+ domknięcie zbioru zależności F
  (wszystkie zależności, którą muszą zachodzić gdy zależności z F zachodzą)
- Dla F — zbioru zależności R, rzutem F na R_i jest $F_i = \{\alpha \to \beta \in F^+ \mid \alpha, \beta \subseteq R_i\}$.
- Dla r — stanu relacji R, stanem R_i jest $r_i = \pi_{R_i}(r)$.
- Złączenie naturalne jest operacją przeciwną do rozkładu.
- Rozkład R na $R_1, \ldots, R_k$ jest odwracalny, jeśli dla każdego poprawnego stanu r (spełniającego zależności F) zachodzi:

$$r \;=\; r_1 \bowtie r_2 \bowtie \cdots \bowtie r_k$$

- Rozkład R na $R_1, \ldots, R_k$ zachowuje zależności, jeśli:

$$F^+ \;=\; (F_1 \cup F_2 \cup \ldots \cup F_k)^+$$

- Rozkład relacji na składowe MUSI być odwracalny i POWINIEN zachowywać zależności.

Rozkład relacji do BCNF

Lemma

Niech R będzie relacją i F jej zbiorem zależności funkcyjnych. Jeżeli $\alpha \to \beta \in F^+$ jest nietrywialna ($\alpha \cap \beta = \emptyset$), to rozkład R na $R_1 = \alpha\beta$ i $R_2 = R \setminus \beta$ jest odwracalny.

Lemma

*Każda relacja ma **odwracalny** rozkład na składowe w BCNF.*

Lemma

*Istnieją relacje, które nie mają **odwracalnego i zachowującego zależności** rozkładu na składowe w BCNF.*

Przykład

`Lokalizacje(Miasto, Gang)`, `Zajęcia(Gang, Proceder)` vs. `Miasto, Proceder` $\to$ `Gang`

Trzecia postać normalna

Definition (Trzecia postać normalna, 3NF)

Relacja R z zależnościami funkcyjnymi F jest w trzeciej postaci normalnej, jeśli każda zależność $\alpha \to B \in F$

- jest trywialna ($B \in \alpha$) albo
- wynika z nadklucza ($(\alpha)_F^+ = R$) albo
- ma po prawej stronie atrybut główny (B należy do jakiegoś klucza).

Lemma

Każda relacja ma odwracalny i zachowujący zależności rozkład na składowe w postaci 3NF.

Algorytm rozkładu do 3NF

Definition (F_{min})

Minimalnym pokryciem zbioru zależności funkcyjnych F nazwiemy równoważny F zbiór F_{min}, w którym:

- nie ma zależności trywialnych, np. $AB \to AC$
- nie ma zależności nadmiarowych, czyli wynikających z pozostałych zależności F_{min}, np. $A \to B, B \to C, A \to C$
- nie ma atrybutów lewostronnie nadmiarowych $AB \to C, A \to B$.

Algorytm rozkładu do 3NF

1. Wyznacz F_{min}.
2. Dla każdej zależności $\alpha \to \beta \in F_{min}$ utwórz składową $R_i = \alpha\beta$. Usuń składowe zawierające się w innych.
3. Jeśli żadna z utworzonych składowych nie zawiera klucza R, to dodaj do rozkładu składową K dla pewnego klucza K relacji R.

Przykład c.d.

- `Mafia(Miasto, Gang, Proceder, Szef)`
- ξ_1: `Gang` $\rightarrow$ `Miasto`, ξ_2: `Miasto, Proceder` $\rightarrow$ `Gang`, ξ_3: `Gang` $\rightarrow$ `Szef`
- Jakie są klucze relacji `Mafia`?
- Podaj odwracalny i zachowujący zależności rozkład relacji `Mafia` do postaci 3NF.
- `Miasta(Gang, Miasto)`, `Mafia(Miasto, Gang, Proceder)`, `Szefowie(Gang, Szef)`
- Dlaczego zachowuje zależności?
- Dlaczego jest odwracalny? Wskazówka: Zacznij od krotki z relacji z kluczem
- cf. BCNF: `Miasta(Miasto, Gang)`, `Procedery(Gang, Proceder)`, `Szefowie(Gang, Szef)`

6NF (!)

- Co najwyżej 1 kolumna, która nie jest częścią klucza,
- Najbardziej rozdrobniona baza jak się da... (inna nazwa: DKNF)
- Przykład - graf: schemat z tabelami dla wierzchołków, krawędzi, własności wierzchołków i krawędzi.

Reguły dla zależności funkcyjnych

Definition (Aksjomaty Armstronga i in.)

Dla relacji R i zbiorów jej atrybutów $\alpha, \beta, \gamma \subseteq R$ zachodzi:

Zwrotność $(\beta \subseteq \alpha) \Rightarrow (\alpha \to \beta)$ (zależności trywialne)

Rozszerzanie $(\alpha \to \beta) \Rightarrow (\alpha\gamma \to \beta\gamma)$

Przechodniość $(\alpha \to \beta \wedge \beta \to \gamma) \Rightarrow (\alpha \to \gamma)$

Sumowanie $(\alpha \to \beta \wedge \alpha \to \gamma) \Rightarrow (\alpha \to \beta\gamma)$

Rozkładanie $(\alpha \to \beta\gamma) \Rightarrow (\alpha \to \beta \wedge \alpha \to \gamma)$

Definition (Domknięcie zbioru zależności i zbioru atrybutów)

Dla relacji R i jej zbioru zależności funkcyjnych F:

F^+ — **domknięciem zbioru zależności** F nazywamy zbiór wszystkich zależności wyprowadzalnych z F.

$(\alpha)_F^+$ — **domknięciem zbioru atrybutów** $\alpha \subseteq R$ **względem** F nazywamy zbiór atrybutów, które można wyprowadzić z α za pomocą F.

Twierdzenie o znaczeniu Aksjomatów Armstronga

Definition (Aksjomaty Armstronga)

Dla relacji R i zbiorów jej atrybutów $\alpha, \beta, \gamma \subseteq R$ zachodzi:

Zwrotność $(\beta \subseteq \alpha) \Rightarrow (\alpha \to \beta)$ (zależności trywialne)

Rozszerzanie $(\alpha \to \beta) \Rightarrow (\alpha\gamma \to \beta\gamma)$

Przechodniość $(\alpha \to \beta \wedge \beta \to \gamma) \Rightarrow (\alpha \to \gamma)$

Theorem

Aksjomaty Armstronga stanowią zupełny, niesprzeczny i minimalny zbiór reguł pozwalający wyprowadzić ze zbioru zależności F każdą zależność funkcyjną prawdziwą w każdym stanie relacji, w którym spełnione są reguły F.

Uwagi ad. domknięcia zbiorów zależności i atrybutów

1. Zazwyczaj nie wyznaczamy F^+ — to zbiór duży i zawierający dużo nieciekawych informacji (np. zależności trywialne).
2. Efektywne wyznaczanie $(\alpha)_F^+$ jest potrzebne — pozwala zadecydować, co jest kluczem, czy w relacji jest redundancja itp.
3. Mamy algorytm, który pozwala wyznaczać $\chi = (\alpha)_F^+$:
   - $\chi \leftarrow \alpha$ (zwrotność)
   - dopóki χ zmienia się:
     - znajdź $\beta \in \chi$ taki, że istnieje $\beta \rightarrow \gamma \in F$ oraz $\gamma \setminus \chi \neq \emptyset$
     - $\chi \leftarrow \chi \cup \gamma$ (zastosuj rozszerzanie i przechodniość)
   - zwróć χ jako wynik
4. Mamy sposób, by porównywać zbiory zależności F i G dla tej samej relacji. Sprawdzamy, czy $F^+ = G^+$:
   - dla każdej zależności $\alpha \rightarrow \beta \in F$:
     - oblicz $\chi = (\alpha)_G^+$
     - jeśli $\beta \subseteq \chi$, to $\alpha \rightarrow \beta \in G^+$, w przeciwnym wypadku $F^+ \neq G^+$
   - powtórz to dla każdej zależności $\alpha \rightarrow \beta \in G$ i zbioru F
5. Zależności funkcyjne powinny być kontrolowane przez SZBD. Dlatego dobrze, by było ich mało. Zbiór F_{min} nazwiemy minimalnym pokryciem F jeśli jest równoważny F i nie zawiera zależności "nadmiarowych".